



UNAM
POSGRADO



Programa
Universitario
de Estudios
del Desarrollo
UNAM

Muestreo de las distribuciones posteriores I: MCMC. Metropolis y Gibbs

Dr. Héctor Nájera
Dr. Curtis Huffman

Sesión anterior

Teorema de Bayes: priors, verosimilitud y posterior

- Escenario clásico de pruebas médicas: imagine una prueba de sangre que detecta vampirismo

- En una población de 100,000 personas, 100 de ellos son vampiros (0.1 %)

$$\Pr(vampiro) = 0.001$$

- De los 100 que son vampiros, 95 de ellos saldrán positivos a vampirismo

$$\Pr(resultado\ positivo | vampiro) = 0.95$$

- De los 99,900 mortales, 999 de ellos saldrán positivos a vampirismo

$$\Pr(resultado\ positivo | mortal) = 0.01$$

Si probamos a las 100,000 personas, ¿qué proporción de ellos que salgan positivo a vampirismo son de hecho vampiros?

$$\Pr(vampiro | resultado\ positivo) = \frac{95}{1094} \approx 0.087$$

¡La posterior es deducida lógicamente!



- Sin garantías excepto que es lógico (matemáticamente correcto)
- La teoría de la probabilidad es un método para deducir implicaciones lógicas de los **datos bajo supuestos que usted debe escoger** (pasar el escrutinio de la audiencia más escéptica)
- Cualquiera que les venda algo diferente está ocultando sus supuestos (**sin modelo no se puede calibrar la incertidumbre**)

Resumir y analizar la posterior

- Preguntas comunes (puntuales y por intervalo)
 - ¿Qué tan creíble es que el valor de un parámetro se encuentre debajo de un valor específico?
 - ¿Qué tan creíble es que el valor de un parámetro se encuentre entre dos valores específicos?
 - ¿Debajo de qué valor del parámetro se encuentra el 5 % de la probabilidad posterior?
 - ¿Qué rango de parámetros contiene el 90 % de la probabilidad posterior?
 - ¿Qué valor del parámetro tiene la mayor probabilidad posterior?
- Pueden responderse integrando la posterior
 - Lo fundamental es la masa de probabilidad, ¡no la densidad!




Figure 4.4: A normal probability density function, shown with a comb of narrow intervals. The integral is approximated by summing the width times height of each interval. Copyright © Kruschke, J. K. (2014). *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan*. 2nd Edition. Academic Press / Elsevier.

Probability Density Function

$$F(x) = P(a \leq x \leq b) = \int_a^b f(x) dx \geq 0$$

Solución analítica (a menudo imposible)

- Hay verosimilitudes sencillas

$$h_i \sim \text{Normal}(\mu, \sigma) \rightarrow \text{Likelihood}$$


$$\mu \sim \text{Normal}(178, 20) \rightarrow \text{Prior}$$

$$\sigma \sim \text{Uniform}(0, 50) \rightarrow \text{Prior}$$


- Monstruo bajo el teorema de Bayes

$$Pr(\mu, \sigma | h) = \frac{\prod_i \text{Normal}(h_i | \mu, \sigma) \text{Normal}(\mu | 178, 20) \text{Uniform}(\sigma | 0, 50)}{\int \int \prod_i \text{Normal}(h_i | \mu, \sigma) \text{Normal}(\mu | 178, 20) \text{Uniform}(\sigma | 0, 50) d\mu d\sigma}$$


Soluciones (¡?)



(1) Trapezoidal Rule



(2) Gaussian Quadrature



Impráctico en altas dimensiones

- 6 parámetros
- El espacio de los parámetros es de seis dimensiones –distribución conjunta de todos los parámetros–
- 1,000,000,000,000,000,000 de valores de los parámetros

0 dimensions:

POINT



1 dimension:


LINE SEGMENT



2


dimensions:

SQUARE




3 dimensions:


CUBE



4 dimensions:

TESSERACT








Calculando la posterior

- Solución analítica (a menudo imposible)
- Aproximación de rejilla (muy intensiva)
- Aproximación por cuadratura (limitada)

Calculando la posterior

- Solución analítica (a menudo imposible)
- Aproximación de rejilla (muy intensiva)
- Aproximación por cuadratura (limitada)
- Muestrear la posterior
 - Métodos de Monte Carlo basados en cadenas de Markov (intensiva)





Esta sesión

Muestreando la posterior


- Capítulo 3: Muestreando el imaginario. *Statistical rethinking: A Bayesian course with examples in R and Stan*, Chapman and Hall/CRC, 2020
- Capítulo 7: Markov Chain Monte Carlo. *Doing Bayesian analysis*. John K. Kruschke, 2018.

¿Dijo usted muestrear?

Tenemos dos tipos principales de muestreo en estadística

Muestreo de encuestas
(survey sampling)



TOTAL POPULATION



SAMPLE POPULATION



Muestreo a partir de una distribución de probabilidad




Una **muestra aleatoria** tiende a exhibir las mismas propiedades que la población de la que fue extraída

Muestrear para resumir

- La posterior representada por un conjunto de muestras a partir de las cuales es posible calcular su esperanza eficientemente

$$p(\theta|\mathcal{D}) \rightarrow \{\theta_1, \dots, \theta_n\}$$



$$\mathbb{E}[f(\theta)] \approx \frac{1}{N} \sum_{n=1}^N f(\theta_i)$$

¿Muestrear a partir de una distribución?

- Induciendo ignorabilidad (a partir de números pseudo-aleatorios) en una estructura apropiada de forma iterada


D10004		f_x	=D10002/C10002	
	A	B	C	D
1	Coin	Flip	Head	Head Fair
2	U	H	1	
3	U	H	1	
4	F	H	1	1
5	U	H	1	
6	F	H	1	1
7	U	H	1	
8	F	T		
9995	F	H	1	1
9996	F	T		
9997	F	T		
9998	U	H	1	
9999	U	H	1	
10000	F	T		
10001	F	H	1	1
10002	5019		7471	2490
10003				
10004	P(F)= 0,5019		P(F1 H1)=	0,33329

A2=SI(**ALEATORIO()**<0.5,"F","U")

B2=SI(A2="U","H",SI(**ALEATORIO()**<0.5,"H","T"))

C2=SI(B2="H",1,"")

D2=SI(Y(A2="F",B2="H"),1,"")



Muestreo de densidades




Figure from PRML, Bishop (2006)

$$h(y) = \int_{-\infty}^y p(y') \, dy'$$

$$u \sim \text{Uniform}[0,1]$$


$$\text{Sample, } y(u) = h^{-1}(u)$$

En el “mundo real” no es nada fácil
muestrear a partir de distribuciones
complicadas.

Método de Monte Carlo

¿Qué hay de aleatorio en π ?


Buffon-Laplace



$$\frac{A_c}{A_s} = \frac{\pi \cancel{a^2}}{\cancel{a^2}} = \pi$$

$$A_s = a^2 \quad A_c = \pi a^2$$

Muestreo de densidades



Muestreo de densidades

Muestreo por rechazo: muestreo de $\pi(x)$ usando $q(x)$ de fácil manejo





Figure credit: Ryan P. Adams

Muestreo de densidades

Muestreo de importancia: reescriba la integral bajo una distribución simple


$$\int f(x) P(x) dx = \int f(x) \frac{P(x)}{Q(x)} Q(x) dx,$$


Aplique Monte Carlo
a “cualquier” integral



$$\approx \frac{1}{S} \sum_{s=1}^S f(x^{(s)}) \frac{P(x^{(s)})}{Q(x^{(s)})}, \quad x^{(s)} \sim Q(x)$$


↑
Ponderador de importancia





Los Métodos Montecarlo aplicados a Cadenas de Markov permiten (tarde o temprano) recuperar las distribuciones objetivo.


- Metropolis (1953)
- Metropolis-Hastings (1970)
- Gibbs (1984)
- Hamiltoniano (o híbrido; 1987)



¿Dijo usted cadenas de Markov?

- Una cadena de Markov es un modelo (gráfico) de probabilidad que tiene la propiedad de Markov.
- La propiedad de Markov (de orden 1) consiste en suponer que en una serie de variables aleatorias $X_1, X_2, \dots, X_n$, cada variable aleatoria sólo depende de la más reciente y no del resto.

$$P(X_i | X_{i-1}, X_{i-2}, \dots, X_2, X_1) = P(X_i | X_{i-1})$$



Algoritmo Metropolis

- Este algoritmo muestrea de una función objetivo complicada (la posteriori) usando una distribución simple como propuesta de transición a partir de la última posición.
 - Se arranca de una posición aleatoria cualquiera (válida) en el espacio de parámetros.
 - Con base en la ubicación actual, se extrae de manera aleatoria, de una función de distribución simple y simétrica, una propuesta del siguiente paso (en la vecindad) a dar.
 - Si el paso conduce a un punto con mayor densidad de probabilidad (evaluando la posteriori en el punto), se acepta la propuesta y se avanza en la dirección planteada.
 - Si el paso conduce a un punto con menor densidad, se acepta la propuesta con probabilidad igual a la proporción de densidad que la propuesta representa de la posición actual. Si la propuesta se rechaza la posición actual se cuenta de nuevo.




Figure 5. Metropolis algorithm for MCMC sampling: (a) x_i is accepted as a drawn sample from $P^*(X)$, (b) The previously drawn sample becomes x_{i-1} in this iteration. The x_i may be accepted as a drawn sample from $P^*(X)$ with probability $P^*(x_i)/P^*(x_{i-1})$.

Algoritmo Metropolis



Rosenbluth


Teller

Metropolis

Arianna

Diagrama de flujo del algoritmo Metropolis

¡Tan sencillo que cabe en un tweet!



Richard McElreath

@rilmcelreath



```
y=sum(rpois(20,2))
n=1e4
p=rep(1,n)
for(i in 2:n){
  r=p[i-1]
  q=exp(log(r)+rnorm(1)/9)
  p[i]=ifelse(runif(1)<q^y*r^(-y)*exp(-20*(q-r)),q,r)
}
```

9:53 AM · May 18, 2016






34 2 Share this Tweet

El camino a la posterior - MH

Monte Carlo }
Markov Chains } MCMC

Algoritmo de Metrópolis



Monte Carlo

Monte Carlo

$$\theta_t \sim N(\mu, \sigma)$$




Pausa (k)

Markov Chain Monte Carlo

$$\theta_t \sim N(\theta_{t-1}, \sigma)$$



Metropolis-Hastings MCMC



$$\text{Step 1: } r(\theta_{\text{new}}, \theta_{t-1}) = \frac{\text{Posterior}(\theta_{\text{new}})}{\text{Posterior}(\theta_{t-1})} = \frac{\text{Beta}(1,1,0.088) \times \text{Binomial}(10,4,0.088)}{\text{Beta}(1,1,0.286) \times \text{Binomial}(10,4,0.286)} = 0.039$$


$$\text{Step 2: Acceptance probability } \alpha(\theta_{\text{new}}, \theta_{t-1}) = \min\{r(\theta_{\text{new}}, \theta_{t-1}), 1\} = \min\{0.039, 1\} = 0.039$$

$$\text{Step 3: Draw } u \sim \text{Uniform}(0,1) = 0.247$$


$$\text{Reproducir (k) If } u < \alpha(\theta_{\text{new}}, \theta_{t-1}) \rightarrow \text{If } 0.247 < 0.039 \text{ Then } \theta_t = \theta_{\text{new}} = 0.088$$

M-H Dos variables

Markov chains




Posterior density




Simulaciones

- La manera más fácil de entender cómo funcionan estos algoritmos es verlos trabajar. Se pueden probar diferentes simulaciones de MCMC escritas por Chi Feng [aquí](#).




Algoritmo Metropolis

- A pesar de ir “dando tumbos” en una *senda aleatoria*, el algoritmo de Marshall y Arianna Rosenbluth (y su generalización Metropolis-Hastings) funciona, pero ese es justo su problema: **es demasiado aleatorio**.
 - Gasta muchísimo tiempo reexplorando las mismas partes de la distribución objetivo desperdiciando tiempo de cómputo valioso.
 - Prácticamente sólo es eficiente en el caso normal/gausiano de bajas dimensiones donde el *conjunto típico* (la parte del dominio que concentra la mayor parte de la probabilidad) es una hiperesfera “bonita” (convexa).



Buenas y malas muestras

Tamaño del salto



Los problemas en la exploración con MCMC

Por qué es un problema?




Figure 7.12: Autocorrelation of a chain. Upper panels show examples of lagged chains. Middle panels show scatter plots of chain values against lagged chain values, with their correlation annotated. Lowest panel shows the autocorrelation function (ACF). Copyright © Kruschke, J. K. (2014). *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan*. 2nd Edition. Academic Press / Elsevier.

Algoritmo Gibbs (MH)



De izquierda a derecha, Stuart y Donald Geman, Paris 1983

- El muestreo Gibbs es un caso particular de MH que modifica la distribución de donde se extraen las propuestas de siguiente paso en la senda aleatoria.
 - A cada paso de la senda, sólo una de las dimensiones del espacio de parámetros es seleccionada, y la propuesta de paso siguiente se extrae de manera aleatoria de la **distribución posterior condicional** (univariada) de ese parámetro, $p(\theta_1 | \{\theta_{j \neq 1}\}, D)$.

Noten que este algoritmo requiere que se pueda muestrear **directamente** de todas las distribuciones condicionales.





Figure 7.7 Two steps in a Gibbs sampling. In the upper panel, the heavy lines show a slice through the posterior conditionalized on a particular value of θ_2 , and the large dot shows a random value of θ_1 sampled from the conditional density. The lower panel shows a random generation of a value for θ_1 , conditional on the value for θ_2 determined by the previous step. The heavy lines show a slice through the posterior at the conditional value of θ_1 , and the large dot shows the random value of θ_2 sampled from the conditional density.


Algoritmo Gibbs (MH)

- Debido a que el muestreo a la Gibbs sólo cambia un parámetro a la vez, éste puede “atascarse” (dar pasos muy pequeños) con parámetros altamente correlacionados (conjuntos típicos esveltos).



MH vs Gibbs


Metropolis-Hastings



Metropolis-Hastings is great, simple, and general. BUT ... sensitive to step size. AND ... can be too slow, because it can end up rejecting a great many steps.

Lo que ustedes quieren son más muestras de calidad (efectivas) en menos tiempo!

Gibbs sampling



De qué depende que sean más eficientes?




Mirando el Gibbs

- La manera más fácil de entender cómo funcionan estos algoritmos es verlos trabajar. Se pueden probar diferentes simulaciones de MCMC escritas por Chi Feng [aquí](#).


¿Conjuntos típicos esbeltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales



¿Conjuntos típicos esbeltos?

- Recuerden que, en el caso continuo, la masa de probabilidad está dada no meramente por la densidad (la altura de la función), sino por el **área** (base x altura) bajo la curva: el límite del área de los rectángulos rojos cuando la base tiende a cero (la integral)



¿Conjuntos típicos esveltos?


- La densidad (la altura), $f(x)$, puede ser mucha (la moda), pero si el dominio (la base) recorre poca distancia (área/volumen, dt), la masa de probabilidad que acumula (la integral) es despreciable.

¿Cómo puede recorrer poca distancia (área/volumen) el dominio?



¿Conjuntos típicos esveltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).



¿Conjuntos típicos esbeltos?


- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).





¿Conjuntos típicos esveltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).




¡Treinta parámetros
no es nada para un
modelo!

Área cubierta

$$10^{-13} = 0.0000000000001$$

¿Conjuntos típicos esbeltos?


- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).



- Con sólo 30 dimensiones (parámetros), el recorrido/área/volumen cubierto por una hiperesfera circunscrita en ese espacio es proporcional a la de un grano de arroz en una cancha de fútbol.
- La densidad puede ser mucha cerca de la moda (el centro de la cancha), pero el recorrido del dominio es despreciable.
- Hay muchísima más área lejos de la moda.

¿Conjuntos típicos esveltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).




To illustrate the distribution of volume in increasing dimensions, consider a rectangular partitioning centered around a distinguished point such as the mode. The relative weight of the center partition is **(a)** $1/3$ in one dimension, **(b)** $1/9$ in two dimensions, **(c)** and only $1/27$ in three dimensions. In d dimensions there are 3^{d-1} neighboring partitions. Very quickly the volume in the center partition becomes negligible compared to the neighboring volume. This effect only amplifies if we consider larger regions around the mode, i.e. partitions beyond the nearest neighbors. For instance, for next-to-nearest neighbors, the base would be 5^{d-1} .

- Con sólo 30 dimensiones (parámetros), el recorrido/área/volumen cubierto por una hiperesfera circunscrita en ese espacio es proporcional a la de un grano de arroz en una cancha de fútbol.
- La densidad puede ser mucha cerca de la moda (el centro de la cancha), pero el recorrido del dominio es despreciable.
- Hay muchísima más área lejos de la moda.

¿Conjuntos típicos esbeltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).




In high dimensions a probability density $\pi(\mathbf{q})$ will concentrate around its mode, but the volume $d\mathbf{q}$ over which we integrate that density is much larger away from the mode. Contributions to expectations are determined by the product $\pi(\mathbf{q}) d\mathbf{q}$. In sufficiently high dimensions, this condition is satisfied only in a nearly-singular region of $\mathcal{Q}$ called the typical set. (This plot only shows a 10-dimensional independent, identically-distributed unit Gaussian. Hence the finite width of the typical set.. $\mathbf{q}$ is the full 10-dimensional vector in parameter space and q in the above figure denotes its radial component.)

- Como aumenta el número de dimensiones (parámetros en el modelo), el conjunto típico (que acumula el grueso de la masa de probabilidad) se vuelve súper esbelto y prácticamente imposible de explorar dando tumbos (MH) o à la Gibbs.



¿Conjuntos típicos esbeltos?

En condiciones ideales, las cadenas de Markov exploran la distribución posteriori en tres fases.





(a) First the Markov chain has to converge to the typical set and estimators suffer from initial biases. **(b)** Once the Markov chain finds the typical set and performs its first traverse, the bias decreases rapidly and the estimators become much more accurate. **(c)** As the Markov chain refines its exploration of the typical set, it gradually reduces estimator errors towards zero.



Mirando el Gibbs


- La manera más fácil de entender cómo funcionan estos algoritmos es verlos trabajar. Se pueden probar diferentes simulaciones de MCMC escritas por Chi Feng [aquí](#).

Software



¿Hay otra forma de hacerlo?

Capítulo 14





Referencias

Geman, Stuart and Geman, Donald. Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on pattern analysis and machine intelligence*, PAMI-6(6):721–741, 1984.

Ghojogh, B., Nekoei, H., Ghojogh, A., Karray, F., & Crowley, M. (2020). Sampling algorithms, from survey sampling to Monte Carlo methods: Tutorial and literature review. arXiv preprint arXiv:2011.00901.

Hastings, W Keith. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1): 97–109, 1970.

Metropolis, Nicholas, Rosenbluth, Arianna W, Rosenbluth, Marshall N, Teller, Augusta H, and Teller, Edward. Equation of state calculations by fast computing machines. *The journal of chemical physics*, 21(6):1087–1092, 1953.

Kruschke, J. (2014). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan*.

McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan*. CRC press.

Sitios de interés

<http://albertolumbreras.net/posts/maldicion-dimensionalidad.html>

<https://janosh.dev/blog/hmc-intro>

<https://chi-feng.github.io/mcmc-demo/>

Series y conferencias de Youtube

<https://youtu.be/ciM6wigZK0w>

<https://youtu.be/U56IHGMWjcw>

<https://youtu.be/fsLh-NYhOoU?si=7aLNKXwo6HRMdCfq>



CONTACTO

475+
UNIVERSIDAD
de
MÉXICO
1551 2026

Dr. Héctor Nájera y Dr. Curtis Huffman
Investigadores (SNII II)

Programa Universitario de Estudios del Desarrollo (PUED)
Universidad Nacional Autónoma de México (UNAM)

Antigua Unidad de Posgrado (costado sur de la Torre II de Humanidades), planta baja.
Campus Central, Ciudad Universitaria, Ciudad de México, México.

Tel. (+52) 55 5623 0222, Ext. 82613 y 82616

Tel. (+52) 55 5622 0889

Email: hecatalan@hotmail.com, chuffman@unam.mx



*¡Bienvenidos
estudiantes!*

