



UNAM
POSGRADO




Programa
Universitario
de Estudios
del Desarrollo
UNAM

Muestreo de las distribuciones posteriores II: MCMC, Hamiltonian

Dr. Héctor Nájera
Dr. Curtis Huffman

Masa de probabilidad

- Recuerden que, en el caso continuo, la masa de probabilidad está dada no meramente por la densidad (la altura de la función), sino por el **área** (base x altura) bajo la curva: el límite del área de los rectángulos rojos cuando la base tiende a cero (la integral)



¿Medida de probabilidad?

La masa de probabilidad es lo fundamental, no la densidad

$$\pi: \mathcal{B}(\Omega) \rightarrow [0,1]$$

$$\theta: \Omega \rightarrow \mathbb{R}^n$$

$$d\pi(\theta) = d\theta\pi(\theta)$$


- La inferencia bayesiana es (era) difícil porque integrar es (era) difícil

¿Cómo contestar nuestras preguntas estadísticas?


- $f(\hat{\theta}), \operatorname{argmax} \pi(\theta)$

- Densidades de probabilidad son convenientes computacionalmente
 - Sólo requieren derivadas
 - Buenas propiedades en modelos convexos de bajas dimensiones
- Dejan de funcionar en altas dimensiones

- $\mathbb{E}[f(\theta)] = \int d\theta\pi(\theta) f(\theta)$




- Lo fundamental es la masa de probabilidad, ¡no la densidad!
- Preguntas bien formuladas pueden responderse integrando la posterior





Whirling Arcs of Steel!



Touche! Miss Arianna Wright, state women's champion and city champ in the men's foil tournaments, makes a deep and effective lunge to score a point against Vernon Bordman, who wields a good blade himself.



Arianna Rosenbluth
(1927–2020)

Algoritmo ~~Metropolis~~ Rosenbluth

- Con **suficientes** recursos computacionales, una cadena de Markov bien diseñada explorará el conjunto típico de cualquier distribución **tarde que temprano**
- Desafortunadamente, este comportamiento asintótico es de poca utilidad práctica (adivina y revisa “trueno” en grandes dimensiones)



Algoritmo Gibbs (MH)



De izquierda a derecha, Stuart y Donald Geman, Paris 1983

- El muestreo Gibbs es un caso particular de MH que modifica la distribución de donde se extraen las propuestas de siguiente paso en la senda aleatoria.
 - A cada paso de la senda, sólo una de las dimensiones del espacio de parámetros es seleccionada, y la propuesta de paso siguiente se extrae de manera aleatoria de la **distribución posterior condicional** (univariada) de ese parámetro, $p(\theta_1 | \{\theta_{j \neq 1}\}, D)$.

Noten que este algoritmo requiere que se pueda muestrear **directamente** de todas las distribuciones condicionales.





Figure 7.7 Two steps in a Gibbs sampling. In the upper panel, the heavy lines show a slice through the posterior conditionalized on a particular value of θ_2 , and the large dot shows a random value of θ_1 sampled from the conditional density. The lower panel shows a random generation of a value for θ_1 , conditional on the value for θ_2 determined by the previous step. The heavy lines show a slice through the posterior at the conditional value of θ_1 , and the large dot shows the random value of θ_2 sampled from the conditional density.

Algoritmo Gibbs (MH)


- Debido a que el muestreo a la Gibbs sólo cambia un parámetro a la vez, éste puede “atascarse” (dar pasos muy pequeños) con parámetros altamente correlacionados (conjuntos típicos esveltos).





¿Conjuntos típicos esbeltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).




¡Treinta parámetros
no es nada para un
modelo!

Área cubierta

$$10^{-13} = 0.0000000000001$$



¿Conjuntos típicos esbeltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).



- Con sólo 30 dimensiones (parámetros), el recorrido/área/volumen cubierto por una hiperesfera circunscrita en ese espacio es proporcional a la de un grano de arroz en una cancha de fútbol.
- La densidad puede ser mucha cerca de la moda (el centro de la cancha), pero el recorrido del dominio es despreciable.
- Hay muchísima más área lejos de la moda.

3Blue1Brown. (2026, 27 de febrero). *The most beautiful formula not enough people understand* [Video]. YouTube. <https://youtu.be/fsLh-NYhOoU?si=uktozTKbqdy4cuxw>




¿Conjuntos típicos esveltos?

- La densidad (la altura), $f(x)$, puede ser mucha (la moda), pero si el dominio (la base) recorre poca distancia (área/volumen, dt), la masa de probabilidad que acumula (la integral) es despreciable.

¿Cómo puede recorrer poca distancia (área/volumen) el dominio?




Can big data support big models?



Efficient Bayesian inference with. Hamiltonian Monte Carlo. Michael Betancourt. University of Warwick. Machine Learning Summer School 2014.

¿Conjuntos típicos esveltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).




To illustrate the distribution of volume in increasing dimensions, consider a rectangular partitioning centered around a distinguished point such as the mode. The relative weight of the center partition is **(a)** $1/3$ in one dimension, **(b)** $1/9$ in two dimensions, **(c)** and only $1/27$ in three dimensions. In d dimensions there are 3^{d-1} neighboring partitions. Very quickly the volume in the center partition becomes negligible compared to the neighboring volume. This effect only amplifies if we consider larger regions around the mode, i.e. partitions beyond the nearest neighbors. For instance, for next-to-nearest neighbors, the base would be 5^{d-1} .

- Con sólo 30 dimensiones (parámetros), el recorrido/área/volumen cubierto por una hiperesfera circunscrita en ese espacio es proporcional a la de un grano de arroz en una cancha de fútbol.
- La densidad puede ser mucha cerca de la moda (el centro de la cancha), pero el recorrido del dominio es despreciable.
- Hay muchísima más área lejos de la moda.

¿Conjuntos típicos esbeltos?

- Cosas inesperadas y contraintuitivas ocurren en espacios multidimensionales. Imaginen un círculo (hiperesfera) inscrito(a) en un cuadrado (hipercubo).




In high dimensions a probability density $\pi(\mathbf{q})$ will concentrate around its mode, but the volume $d\mathbf{q}$ over which we integrate that density is much larger away from the mode. Contributions to expectations are determined by the product $\pi(\mathbf{q}) d\mathbf{q}$. In sufficiently high dimensions, this condition is satisfied only in a nearly-singular region of $\mathcal{Q}$ called the typical set. (This plot only shows a 10-dimensional independent, identically-distributed unit Gaussian. Hence the finite width of the typical set.. $\mathbf{q}$ is the full 10-dimensional vector in parameter space and q in the above figure denotes its radial component.)

- Como aumenta el número de dimensiones (parámetros en el modelo), el conjunto típico (que acumula el grueso de la masa de probabilidad) se vuelve súper esbelto y prácticamente imposible de explorar dando tumbos (MH) o à la Gibbs.



¿Conjuntos típicos esbeltos?


En condiciones ideales, las cadenas de Markov exploran la distribución posteriori en tres fases.



(a) First the Markov chain has to converge to the typical set and estimators suffer from initial biases. **(b)** Once the Markov chain finds the typical set and performs its first traverse, the bias decreases rapidly and the estimators become much more accurate. **(c)** As the Markov chain refines its exploration of the typical set, it gradually reduces estimator errors towards zero.

¿Hay otra forma de hacerlo?

Betancourt, M. *A conceptual introduction to Hamiltonian Monte Carlo* arXiv preprint arXiv:1701.02434, 2017
Capítulo 14: Stan. *Doing Bayesian analysis*. John K. Kruschke, 2018.






Esta sesión

Muestreando la posterior

- Betancourt, M. *A conceptual introduction to Hamiltonian Monte Carlo* arXiv preprint arXiv:1701.02434, 2017
- Capítulo 14: Stan. *Doing Bayesian analysis*. John K. Kruschke, 2018.

El cálculo es un súper poder



Explota la geometría del conjunto típico para
informar transiciones de Markov efectivas



El cálculo es un súper poder

- ¿Por qué caminar cuando puedes fluir?

¿El gradiente no es suficiente?
¿Por qué no simplemente optimizamos?



El cálculo es un súper poder

¡La *masa* de probabilidad es lo importante, no la densidad!



$f(x)$



$$\mathbb{E}[f(\theta)] = \int d\theta \pi(\theta) f(\theta)$$



El cálculo es un súper poder

- ¿Por qué caminar cuando puedes fluir?




El cálculo es un súper poder

- ¿Por qué caminar cuando puedes fluir?



Monte Carlo Hamiltoniano (HMC)

- Variación ingeniosa del algoritmo Metrópolis (véase Kruschke 2018, cap. 14) en la que la distribución de propuestas cambia de acuerdo con la posición del más reciente eslabón de la cadena en la dirección del conjunto típico.
 - HMC genera propuestas, por analogía con la exploración de un sistema físico, explotando la geometría del conjunto típico como se rodaría una canica sobre la distribución posterior vuelta de cabeza.



Monte Carlo Hamiltoniano (HMC)

- Toda vez que el gradiente (la derivada multivariada) de la distribución posterior apunta en la dirección de máximo crecimiento de la función, es necesario complementar/contrarestar esta “gravedad” (energía potencial) con otra “fuerza” (energía cinética) que le permita “rodar”/“orbitar” (eternamente) por el conjunto típico (tomando muestras): espacio de fases.





FIG 14. The exploration of a probabilistic system is mathematically equivalent to the exploration of a physical system. For example, we can interpret the mode of the target density as a massive planet and the gradient of the target density as that planet's gravitational field. The typical set becomes the space around the planet through which we want a test object, such as a satellite, to orbit.



Monte Carlo Hamiltoniano (HMC)

- Toda vez que el gradiente (la derivada multivariada) de la distribución posterior apunta en la dirección de máximo crecimiento de la función, es necesario complementar/contrarestar esta “gravedad” (energía potencial) con otra “fuerza” (energía cinética) que le permita “rodar”/“orbitar” (eternamente) por el conjunto típico (tomando muestras): espacio de fases.





FIG 14. The exploration of a probabilistic system is mathematically equivalent to the exploration of a physical system. For example, we can interpret the mode of the target density as a massive planet and the gradient of the target density as that planet's gravitational field. The typical set becomes the space around the planet through which we want a test object, such as a satellite, to orbit.



Monte Carlo Hamiltoniano (HMC)

- Las propuestas se generan tomando aleatoriamente de la distribución de momento (fuerza con la que echamos a andar la canica, dimensión agregada al sistema) dejando “fluir” la “partícula” (rodar la canica) determinísticamente por un tiempo determinado (No U-turn Turn Sampler). La nueva posición es la propuesta a evaluar como siguiente paso en el algoritmo Metropolis.






FIG 17. When we introduce exactly the right amount of momentum to the physical system, the equations describing the evolution of the satellite define a vector field aligned with the orbit. The subsequent evolution of the system will then trace out orbital trajectories.



Monte Carlo Hamiltoniano (HMC)

- Las propuestas se generan tomando aleatoriamente de la distribución de momento (fuerza con la que echamos a andar la canica, dimensión agregada al sistema) dejando “fluir” la “partícula” (rodar la canica) determinísticamente por un tiempo determinado (No U-turn Turn Sampler). La nueva posición es la propuesta a evaluar como siguiente paso en el algoritmo Metropolis.



Trajectories exploring the typical set of a probability distribution in phase space. That phase space distribution marginalizes to the target distribution, thus projecting us from the phase space to the target distribution's typical set.




FIG 22. (a) Each Hamiltonian Markov transition lifts the initial state onto a random level set of the Hamiltonian, which can then be explored with a Hamiltonian trajectory before projecting back down to the target parameter space. (b) If we consider the projection and random lift steps as a single momentum resampling step, then the Hamiltonian Markov chain alternates between deterministic trajectories along these level sets (dark red) and a random walk across the level sets (light red).

Monte Carlo Hamiltoniano (HMC)

- Las propuestas se generan tomando aleatoriamente de la distribución de momento (fuerza con la que echamos a andar la canica, dimensión agregada al sistema) dejando “fluir” la “partícula” (rodar la canica) determinísticamente por un tiempo determinado (No U-turn Turn Sampler). La nueva posición es la propuesta a evaluar como siguiente paso en el algoritmo Metropolis.




Figure 14.1 Examples of a Hamiltonian Monte Carlo proposal distributions. Two columns show two different current parameter values, marked by the large dots. First row shows posterior distribution. Second row shows the potential energy, with a random impulse given to the dot. Third row shows trajectories, which are the theta value (x-axis) as a function of time (y-axis marked Steps*Eps). Fourth row shows histograms of the proposals.


Monte Carlo Hamiltoniano (HMC)

- Aunque atractiva, HMC conduce en principio a una infinidad de posibles transiciones según la distribución de momento que se agregue al sistema, el tamaño y número de pasos (la fuerza con la se le pegue y el tiempo que se deje rodar la canica).
- Afortunadamente los desarrolladores de Stan (Stan Development Team. YEAR. Stan Modeling Language Users Guide and Reference Manual, VERSION. <https://mc-stan.org>), especialistas en geometría diferencial, trabajan constantemente en automatizar la combinación óptima de estas opciones para que los usuarios se puedan concentrar en la formulación de sus modelos estadísticos.




Stan interfaces with the most popular data analysis languages (R, Python, shell, MATLAB, Julia, Stata) and runs on all major platforms (Linux, Mac, Windows).


<https://mc-stan.org/>



Stanisław Ulam and his daughter Claire with MANIAC

Stanisław Ulam (1909–1984)








Mirando el HMC

La manera más fácil de entender cómo funcionan estos algoritmos es verlos trabajar

- Se pueden probar diferentes simulaciones de MCMC escritas por
 - Chi Feng [aquí](#)
 - Alesksey Rogoznikov [aquí](#)

OK Pero en la práctica qué pasa entonces?

(Bayesian inference
Using Gibbs Sampling)




1987

1997

2003

2010



JAGS is Just Another Gibbs Sampler

Rjags
MCMCglmm
RbugsRwinbugs


...

Gibbs sigue dominando pero... años más tarde

¿Un nuevo orden?



¿Dónde se estima?



RStan

The R interface to Stan

Figure 8.1: Relation of R programming language to other software tools. On the left, RStudio is an editor for interacting with R. The items on the right are various programs for generating MCMC samples of posterior distributions. The items in the middle are packages in R that interact with the MCMC generators. Copyright © Kruschke, J. K. (2014). *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan*. 2nd Edition. Academic Press / Elsevier.

Stan: Diferentes plataformas

Stan está escrito
en C++

Programas

rstan

PyStan

Stan.jl

CmdStan

Rstan (crudo)

rstan

(interfaces
para rstan)

rstanarm

rethinking


brms

cmdstanr

Avanzado: mayor potencia y flexibilidad

Intermedio: menor flexibilidad

¿Cómo saber si estamos en presencia del conjunto típico?


$$\lim_{n \rightarrow \infty} \frac{1}{N} \sum_{n=0}^N f(q_n) \rightarrow \mathbb{E}_{\pi}[f]$$

Convergencia de cómputo Bayesiano. Suficiencia y evaluación

- Capítulo 8: MCMC. Statistical rethinking: A Bayesian course with examples in R and Stan Chapman and Hall/CRC, 2020
- Vethari et al. (2021) [Rank-Normalization, Folding, and Localization: An Improved \$\hat{R}\$ for Assessing Convergence of MCMC \(with Discussion\)](#)

If it walks like a duck
talks like a duck,
then it could be
a dragon doing
a duck impersonation.





Referencias

Geman, Stuart and Geman, Donald. Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on pattern analysis and machine intelligence*, PAMI-6(6):721–741, 1984.

Ghojogh, B., Nekoei, H., Ghojogh, A., Karray, F., & Crowley, M. (2020). Sampling algorithms, from survey sampling to Monte Carlo methods: Tutorial and literature review. arXiv preprint arXiv:2011.00901.

Hastings, W Keith. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1): 97–109, 1970.

Metropolis, Nicholas, Rosenbluth, Arianna W, Rosenbluth, Marshall N, Teller, Augusta H, and Teller, Edward. Equation of state calculations by fast computing machines. *The journal of chemical physics*, 21(6):1087–1092, 1953.

Kruschke, J. (2014). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan*.

McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan*. CRC press.

Sitios de interés

<http://albertolumbreras.net/posts/maldicion-dimensionalidad.html>

<https://janosh.dev/posts/hmc-intro>

<https://chi-feng.github.io/mcmc-demo/>

Series y conferencias de Youtube

<https://youtu.be/ciM6wigZK0w>

<https://youtu.be/U56IHGMWjcw>

MLSS Iceland 2014 (17 de nov 2014). *Efficient Bayesian inference with Hamiltonian Monte Carlo – Michael Betancourt (Part 1)* [Archivo de Youtube]. <https://youtu.be/pHsulaPbNbY?si=ZkSYzcUPpI4VQ6NZ>



CONTACTO

475+
UNIVERSIDAD
de
MÉXICO
1551 2026

Dr. Héctor Nájera y Dr. Curtis Huffman
Investigadores (SNII II)

Programa Universitario de Estudios del Desarrollo (PUED)
Universidad Nacional Autónoma de México (UNAM)

Antigua Unidad de Posgrado (costado sur de la Torre II de Humanidades), planta baja.
Campus Central, Ciudad Universitaria, Ciudad de México, México.

Tel. (+52) 55 5623 0222, Ext. 82613 y 82616

Tel. (+52) 55 5622 0889

Email: hecatalan@hotmail.com, chuffman@unam.mx



*¡Bienvenidos
estudiantes!*

