





Convergencia de cómputo Bayesiano Suficiencia y evaluación

Dr. Héctor Nájera
Dr. Curtis Huffman


¿Dónde estamos?



¿Dónde estamos?




¿Dónde estamos?



La sesión anterior

El auge del análisis bayesiano aplicado desde finales del siglo pasado se debe a la resonancia de innovaciones en software (algoritmos) y cómputo

([Bayesian inference](#)
Using [Gibbs Sampling](#))




1987

1997

2003

2010



JAGS is Just Another Gibbs
Sampler

Rjags
MCMCglmm
RbugsRwinbugs
R-INLA

...

Gibbs sigue dominando pero... años
más tarde

¿Un
nuevo
orden?



mc-stan.org




Stan

About Stan

Stan is a state-of-the-art platform for statistical modeling and high-performance statistical computation. Thousands of users rely on Stan for statistical modeling, data analysis, and prediction in the social, biological, and physical sciences, engineering, and business.

Stanisław Ulam (1909–1984)



Stan

Hamiltonian Monte Carlo


Modeling
Language

Automatic
Differentiation

Adaptation

Condiciones ideales

En condiciones ideales, las cadenas de Markov exploran la distribución posteriori en tres fases.




(a) First the Markov chain has to converge to the typical set and estimators suffer from initial biases. **(b)** Once the Markov chain finds the typical set and performs its first traverse, the bias decreases rapidly and the estimators become much more accurate. **(c)** As the Markov chain refines its exploration of the typical set, it gradually reduces estimator errors towards zero.

¿Condiciones ideales?


¿Cómo saber si estamos en presencia del conjunto típico?

¿Cómo saber si hemos convergido si nadie sabe qué aspecto tiene?






$$\lim_{n \rightarrow \infty} \frac{1}{N} \sum_{n=0}^N f(q_n) \rightarrow \mathbb{E}_{\pi}[f]$$

¿Dónde estamos?




Evaluación de la calidad de mis muestras

- ¿Cómo saber si la muestra es buena?




¿Muestra buena?

- Los valores de la cadena deberían “representar” adecuadamente la distribución posterior:
 - No deberían verse influenciados por su punto de arranque
 - Deberían explorar el “largo y ancho” de la distribución posterior (no atascarse en su recorrido)



¿Muestra buena?


- Para que nuestras estimaciones sean precisas y estables (representativas) las cadenas generadas deben
 - tener el largo “suficiente”
 - generarse eficientemente (el menor número de pasos posible)
- ¿Cómo reconocer las malas muestras?
 - Diagnósticos de convergencia
 - ¿Cómo se vería una cadena influenciada indebidamente por su punto inicial?



DOS PROPIEDADES:

1. Irreducibilidad → la cadena puede llegar a *cualquier* estado desde *cualquier* otro estado. No hay zonas del espacio aisladas que nunca puedas visitar.

2. Aperiodicidad → la cadena no queda atrapada en ciclos. No oscila entre estados de forma rígida ($A \rightarrow B \rightarrow A \rightarrow B \dots$) Sino que explora libremente.



Espacio típico de solución


Muestras efectivas

Muestras de la marginal


Construcción de la posterior

Ergodicidad geométrica

Fix n $\bar{X}_T = \frac{1}{T} \int_0^T x_n(t) dt$




Fix t $\langle X \rangle_N = \frac{1}{N} \sum_{n=1}^N x_n(t)$



Ergodicidad

$X(t)$ is **ergodic** if $\bar{X} = \langle X \rangle$




Ergodicidad



Ergodic process/measure/system

1 time 100 dice
"space-average"

100 times 1 die
"time average"




=



Ergodicidad

- Tema de la mayor importancia en Economía
 - Se dice que una vacuna es efectiva en 70 % de los casos
 - ¿Es efectiva 70 % de las veces en 100 % de las personas?
 - ¿Es efectiva 100 % de las veces en 70 % de las personas?
- “The idea of the average patient is a noninformative construct in psychiatry that falls apart when mapping abnormalities at the level of the individual patient.”
 - Wolfers, T., Doan, N. T., Kaufmann, T., Alnæs, D., Moberget, T., Agartz, I., ... & Marquand, A. F. (2018). Mapping the heterogeneous phenotype of schizophrenia and bipolar disorder using normative models. *JAMA psychiatry*, 75(11), 1146-1155.
- Lack of group-to-individual generalizability
 - Van Geert, P. (2011). The contribution of complex dynamic systems to development. *Child Development Perspectives*, 5(4), 273-278.

Figure 5. Characterization of Extreme Deviations From the Normative Model in Patients With Bipolar Disorder




Ergodicidad

- Cuando las cadenas convergen
 - El inicio y el final de cada cadena explora la misma región
 - Cadenas independientes exploran la misma región

Converged



Not converged



Condiciones necesarias (no suficientes)

- Diagnósticos visuales
 - Trace plots
 - Trace rank plots
- Diagnósticos numéricos
 - Rhat
 - Número de muestras efectivas
 - Transiciones divergentes


**If it walks like a duck
talks like a duck,
then it could be
a dragon doing
a duck impersonation.**



Diagnósticos visuales




Trace plots




Inspección visual

- ¿Cómo se vería una cadena influenciada indebidamente por su punto inicial?





Trace and density plots




Trace plots

Estacionariedad visual




Inspección visual

- ¿Se observan cadenas aisladas?
- ¿Alguna cadena parece haberse atascado por algún tiempo?
- ¿Alguna cadena parece haberse estabilizado muy lentamente?



¿A veces la cadena se atasca?





No podemos explorar este vecindario


~~Ergodicidad~~


Trace plots

, chains=4 , cores=4)



















Exploración ineficiente







Inspección visual

No siempre la inspección visual es de libro de texto



Rank plots (trace ranks o “tranks”)

- Histogramas de las muestras ordenadas (cuantiles sobre todas las cadenas) graficadas para cada cadena por separado
- A diferencia de las traceplots, tranks no tienden a “apelotonarse” sin dejar ver nada con cadenas largas





Trace rank



En vez de graficar el valor θ en cada iteración, graficas el **rango** de ese valor dentro del conjunto total de muestras de todas las cadenas.

← todos los rangos visitados

Trace rank





Diagnósticos numéricos



Inspección numérica: Rhat

- Varianza: potential scale reduction factor, shrink factor, Rhat, $\hat{R}$ (Gelman & Rubin, 1992; Vehtari et al., 2020)
 - ¿Cuánta varianza hay **entre** cadenas en relación con cuánta varianza hay **al interior** de las cadenas?
 - Si todas las cadenas se estabilizaron en una muestra representativa, la diferencia promedio entre las cadenas debería ser la misma que la diferencia promedio al interior (entre pasos) de las cadenas




$\hat{R}$ (Rhat)



Si las cadenas convergen,

- El inicio y el final de cada cadena exploran la misma región (la cadena es estacionaria)
- Las diferentes cadenas exploran el mismo lugar


El cociente de varianzas:
Conforme la varianza total
(de todas las cadenas) se
acerca al promedio de la
varianza en las cadenas, $\hat{R}$ (R-
hat) se acerca a 1



$\hat{R}$ (Rhat)

- ¿Qué pasa si las cadenas exploran diferentes regiones?

Advertencia: hace falta una buena estimación de la varianza



La varianza total (de todas las cadenas combinadas) $>$ el promedio de la varianza en las cadenas (por separado)

Inspección numérica

- Precisión: cadenas... ¿suficientemente largas?
 - Información independiente sobre la distribución posterior
 - Autocorrelación como una medida de “atasques”(terrones) en la cadena donde valores consecutivos contienen mucha información redundante.




Figure 7.12 Autocorrelation of a chain. Upper panels show examples of lagged chains. Middle panels show scatter plots of chain values against lagged chain values, with their correlation annotated. Lowest panel shows the autocorrelation function (ACF).


Número de muestras efectivas (ESS)

rank – normalized $ESS > 400$



- Una aproximación contrafactual a “¿Qué tan larga sería la cadena si cada muestra fuese independiente de la anterior?” (# muestras independientes)
- Cuando las muestras están autocorrelacionadas se tienen menos muestras efectivas

¿Effective Sample Size $\gtrsim$ total post – warmup draws?




Inspección numérica

- Tamaño de muestra efectivo (ESS): largo de una cadena completamente no-autocorrelacionada que contiene la misma cantidad de información de la cadena de Markov bajo consideración.
- ¿Cuál sería un tamaño de muestra efectivo mínimo para hacernos una idea razonable de la distribución posterior?
 - Depende de la “resolución” (precisión) requerida.
- Monte Carlo standard error (MCSE)
 - Igual que el error estándar clásico, pero en términos del tamaño de muestra efectivo (ESS)

Transiciones divergentes

Regiones de alta curvatura




Iteration

Pasos más pequeños

Warning messages:

1: There were 2 divergent transitions after warmup.
Increasing `adapt_delta` above 0.8 may help.

Transiciones divergentes



→ Pasos más pequeños

Muestreo de la posterior


Especificación

- **Burn-in –warm up-**: Periodo inicial de calentamiento -20% de las iteraciones totales-
- **Iteraciones totales**: Total de iteraciones que elegimos (10,000 GIBSS MH; 1,500 HMC-NUTS)
- **Cadenas**: Por lo menos 2. Pero una por núcleo de la computadora.
 - ¿Opcional **Thinning?**: Si en la primera Vuelta el ESS es pequeño, revisa autocorrelación serial y ajusta
- Inspección visual
 - ¿Importa el inicio de la cadena?
 - ¿Exploración similar a una caminata aleatoria en torno al espacio típico?
 - ¿Hay autocorrelación seria?
 - ¿Las posteriors son consistentes con los priors?

Lista: Diagnósticos de convergencia



- Inspección visual de los trace y density plots.
- Inspección de la varianzas entre e intra cadenas (Rhat)
- Tamaño de muestra efectivo: $>5,000$ GIBBS-MH; >400 HMC-NUTS
- Error estándar de Monte Carlo
- Es importante advertir que la lógica de los diagnósticos revisados opera en una sola dirección (son condiciones necesarias, no suficientes)

Diagnósticos necesarios, no suficientes



Diagnósticos necesarios, no suficientes

¿Cómo se verían las cadenas?



Los diagnósticos “tradicionales” pueden fallar

Durante mucho tiempo el $\hat{R}$ se usó sin muchos cuestionamientos: ¿1.05?

Lo mismo puede decirse del ESS: Global ESS

Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC*


Aki Vehtari,[†] Andrew Gelman,[‡] Daniel Simpson,[§] Bob Carpenter,[¶] and Paul-Christian Bürkner[†]

Abstract

Markov chain Monte Carlo is a key computational tool in Bayesian statistics, but it can be challenging to monitor the convergence of an iterative stochastic algorithm. In this paper we show that the convergence diagnostic $\hat{R}$ of Gelman and Rubin (1992) has serious flaws. Traditional $\hat{R}$ will fail to correctly diagnose convergence failures when the chain has a heavy tail or when the variance varies across the chains. In this paper we propose an alternative rank-based diagnostic that fixes these problems. We also introduce a collection of quantile-based local efficiency measures, along with a practical approach for computing Monte Carlo error estimates for quantiles. We suggest that common trace plots should be replaced with rank plots from multiple chains. Finally, we give recommendations for how these methods should be used in practice.

Por qué es un tema importante

- Nos interesan buenas y grandes muestras de todos los puntos de la distribución posterior



¿Qué si mis cadenas hacen un buen trabajo en el centro pero no en la esquinas?

Esto significaría que mis intervalos creíbles pueden ser poco confiables.

Parelización: Problemas del Rhat tradicional

Con las nuevas computadoras siempre se corren múltiples cadenas

Alguna puede salir mal, especialmente cuando falla en explorar las colas de la distribución posterior.

Antes se usaba $R < 1.1$ o $R < 1.05$

Pero con simulaciones se requiere un criterio más estricto $R < 1.01$




Figure 2: An example showing problems undetected by traditional $\hat{R}$. Each plot shows histograms of $\hat{R}$ values over 1000 replications of four chains, each with a thousand draws. In the left column, one of these four chains was incorrect. In the top left plot, we set one of the four chains to have a variance lower than the others. In the bottom left plot, we took one of the four chains and shifted it. In both cases, the traditional $\hat{R}$ estimate does not detect the poor behavior, while the new value does. In the right column, all the chains are simulated with the same distribution. The chains used for the top row plots target a normal distribution, while the chains used for the bottom row plots target a Cauchy distribution.

El Rhat debe leerse en compañía del ESS

- El Rhat (tradicional) les permite saber si la mezcla de las cadenas es confiable
- El ESS les indica si el número de muestras efectivas es suficientemente grande para tener una estimación estable de incertidumbre
- El problema es que queremos buenas muestras de todos los puntos de la distribución. Se proponen dos adicionales
 - Tail-ESS: It is defined as the minimum of the effective sample sizes for 5% and 95% quantiles.
 - Bulk-ESS: is useful as a generic diagnostic for the sampling efficiency in the bulk of the posterior.




Figure 3: Local efficiency of small-interval probability estimates for the Cauchy model with nominal parameterization. Results are displayed for the element of x with the smallest tail-ESS. The dashed line shows the recommended threshold of 400. Orange ticks show the position of iterations that exceeded the maximum tree depth in the dynamic HMC algorithm.




Figure 4: Efficiency of quantile estimates for the Cauchy model with nominal parameterization. Results are displayed for the element of x with the smallest tail-ESS. The dashed line shows the recommended threshold of 400. Orange ticks show the position of iterations that exceeded the maximum tree depth in the dynamic HMC algorithm.

Salidas


```
Family: zero_inflated_poisson
Links: mu = log; zi = identity
Formula: count ~ persons + child + camper
Data: zinb (Number of observations: 250)
Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
       total post-warmup draws = 4000
```

Population-Level Effects:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	-1.01	0.17	-1.35	-0.68	1.00	3014	2868
persons	0.87	0.04	0.79	0.96	1.00	3097	2835
child	-1.37	0.10	-1.56	-1.17	1.00	2874	2132
camper	0.80	0.09	0.62	0.98	1.00	3318	2689

Family Specific Parameters:

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
zi	0.41	0.05	0.32	0.49	1.00	3159	2575



Salidas

```
Family: zero_inflated_poisson
Links: mu = log; zi = identity
Formula: count ~ persons + child + camper
Data: zinb (Number of observations: 250)
Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
      total post-warmup draws = 4000
```

Population-Level Effects:

	Estimate	Est.Error	1-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	-1.01	0.17	-1.35	-0.68	1.00	3014	2868
persons	0.87	0.04	0.79	0.96	1.00	3097	2835
child	-1.37	0.10	-1.56	-1.17	1.00	2874	2132
camper	0.80	0.09	0.62	0.98	1.00	3318	2689

Family Specific Parameters:

	Estimate	Est.Error	1-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
zi	0.41	0.05	0.32	0.49	1.00	3159	2575

Convergencia

Muestras
efectivas

Parámetros

Moda de
la
posterior

Equivalente
a la SD en
Bayes

Valor 2.5%
de la
distribución
posterior

Valor al
97.5% de
la
posterior

**¿POR QUÉ APARECEN LOS PROBLEMAS DE
CONVERGENCIA?**

The Folk Theorem of Statistical Computing

“When you have computational problems, often there’s a problem with your model.”

Andrew Gelman


Spider-Man of Bayesian data analysis



Causas de pobre cómputo


- Priors del modelo generativo pobremente especificado:
 - Algún o varios priors no son generativos
 - Quizá el prior es generativo pero me equivoqué en la escala
- Parámetros redundantes del modelo generativo:
 - Quizá un parámetro está haciendo un mal trabajo –correlaciones entre parámetros–
- La distribución objetivo del modelo generativo es inadecuada
 - Quizá uso una normal vs log-normal
- La verosimilitud conduce a regiones inesperadas bajo el modelo generativo
 - Datos perdidos
 - Escala de los datos
 - Colinealidad muy severa

Priors del modelo generativo pobremente especificado



Vague priors

Predictions are all over the place



PRIOR ON B (SLOPE)



PRIOR ON A (INTERCEPT)



Lines span impossible temperature changes — priors encode no domain knowledge.

MODEL

$$\Delta\text{Temp} = \alpha + \beta \cdot \text{Growth} + \varepsilon$$

$$\alpha \sim N(0, 8^2)$$


$$\beta \sim N(0, 3^2)$$

$$\varepsilon \sim N(0, \sigma^2)$$

Efecto de priors demasiado vagos sobre las posibilidades que tiene el modelo generativo de crear valores razonables del parámetro de interés

Weakly informative priors

Plausible spread, centred near the expected effect



PRIOR ON B (SLOPE)




PRIOR ON A
(INTERCEPT)




Efecto de priors débilmente informativos sobre las posibilidades que tiene el modelo generativo de crear valores razonables del parámetro de interés

Efecto de priors menos débilmente informativos sobre las posibilidades que tiene el modelo generativo de crear valores razonables del parámetro de interés



Problemas con la distribución objetivo



Problemas/Retos

When I run the model using brms I get:

```
Data: idat (Number of observations: 1826)
Samples: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup samples = 4000

Group-Level Effects:
~ctryear (Number of levels: 74)
      Estimate Est.Error 1-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sd(Intercept)    0.39     0.03   0.34   0.45 1.02      91     241

Population-Level Effects:
      Estimate Est.Error 1-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept    0.21     0.04   0.13   0.30 1.16      28      90
zigdp_pc     0.29     0.01   0.27   0.31 1.02     330     625

Family Specific Parameters:
      Estimate Est.Error 1-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    0.12     0.00   0.12   0.12 1.00    1023    1618

Samples were drawn using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
Warning message:
```

```
Family: gaussian
Links: mu = identity; sigma = identity
Formula: wy ~ zigdp_pc + (1 | ctryear)
Data: dat (Number of observations: 1826)
Samples: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup samples = 4000

Group-Level Effects:
~ctryear (Number of levels: 74)
      Estimate Est.Error 1-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sd(Intercept)    0.39     0.03   0.33   0.46 1.00    6214    2909

Population-Level Effects:
      Estimate Est.Error 1-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept    0.21     0.00   0.20   0.21 1.00    1651    2057
zigdp_pc     0.29     0.01   0.27   0.31 1.00     530    1027

Family Specific Parameters:
      Estimate Est.Error 1-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    0.12     0.00   0.12   0.12 1.00    6207    3161
```

Pobre especificación del modelo –en este caso la ordenada al origen está correlacionada con las ordenadas al origen locales-

Problemas/retos


```

~cluster (Number of levels: 51919)
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sd(Intercept)    0.86     0.01   0.85   0.87 1.01     589     990

~country_num (Number of levels: 62)
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sd(Intercept)    1.12     0.11   0.93   1.36 1.00     178     351

Population-Level Effects:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept      1.41     0.60   0.25   2.56 1.02       74     217
age            -0.01     0.00  -0.01  -0.00 1.00    1397    1273
windex         -0.01     0.00  -0.01  -0.01 1.00    1709    1141
urban          -0.25     0.02  -0.28  -0.21 1.00     543     856
neverunion      0.01     0.02  -0.02   0.04 1.00    1296    1334
work_pay_1     -0.06     0.01  -0.08  -0.04 1.00     933    1070
work_pay_99    -0.14     0.01  -0.17  -0.12 1.00     951    1133
hhld_decision_1 -0.19     0.01  -0.22  -0.17 1.00    1117    1141
hhld_decision_99 -0.24     0.02  -0.27  -0.21 1.00     931    1219
mediaex_1       0.08     0.01   0.06   0.10 1.00    1291    1271
mediaex_2       0.00     0.01  -0.02   0.02 1.00    1188    1113
mediaex_3       0.02     0.02  -0.01   0.05 1.00    1174    1189
education_2     -0.37     0.01  -0.39  -0.34 1.00    1885     981
education_3     -0.75     0.02  -0.78  -0.72 1.00    1868    1311
early_marr      0.08     0.01   0.07   0.10 1.00    2790    1270
mean_edu        -0.59     0.06  -0.69  -0.48 1.00     567     850
mean_wi         0.00     0.00   0.00   0.00 1.00     784     999
mean_prearlymarr 0.01     0.00   0.01   0.01 1.00     619     988
gdp            -1.04     0.32  -1.66  -0.39 1.00     144     216
parliament      0.00     0.01  -0.02   0.03 1.01     132     227
labor_fem       -0.02     0.01  -0.04   0.00 1.01      85     170
SecEducCountry  -0.01     0.01  -0.03   0.01 1.02     143     265



```



Muy pocas muestras para algunos parámetros. No es casual que sean los efectos a nivel país. ¿Priors o cadenas cortas?

La convergencia es una condición necesaria pero insuficiente

mu[1]



Resumiendo

Calibración/Modelación:

- Especificación de hipótesis: Efecto de X sobre Y
- Especificación del modelo generativo y determinístico –verosimilitud: binario, gaussiano, neg-binomial, gamma, multinivel, AR-
- Identificación de parámetros: Todos los parámetros θ
- Especificación de prioris –En el contexto de la verosimilitud-
- Exploración de la posterior con mi algoritmo favorito

Evaluación:

- Inspección visual de las cadenas
- Rhat (< 1.01), Bulk y Tail ESS > 400 –HMC-. Con GIBBS o MH > 10000
- Chequeos predictivos posteriores –Reproduce mi modelo los datos?-

Referencias

- Gelman, A., & Rubin, D. B. (1992). Inference from iterative simulation using multiple sequences. *Statistical science*, 7(4), 457-472.
- Geman, Stuart and Geman, Donald. Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on pattern analysis and machine intelligence*, PAMI-6(6):721–741, 1984.
- Ghojogh, B., Nekoei, H., Ghojogh, A., Karray, F., & Crowley, M. (2020). Sampling algorithms, from survey sampling to Monte Carlo methods: Tutorial and literature review. arXiv preprint arXiv:2011.00901.
- Hastings, W Keith. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1): 97–109, 1970.
- Metropolis, Nicholas, Rosenbluth, Arianna W, Rosenbluth, Marshall N, Teller, Augusta H, and Teller, Edward. Equation of state calculations by fast computing machines. *The journal of chemical physics*, 21(6):1087–1092, 1953.
- Kruschke, J. (2014). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan*.
- McElreath, R. (2020). *Statistical rethinking: A Bayesian course with examples in R and Stan*. CRC press.
- Aki Vehtari, Andrew Gelman, Daniel Simpson, Bob Carpenter, Paul-Christian Bürkner (2020): Rank-normalization, folding, and localization: An improved R-hat for assessing convergence of MCMC. *Bayesian analysis*, accepted for publication. arXiv preprint arXiv:1903.08008.

CONTACTO

Dr. Héctor Nájera y Dr. Curtis Huffman
Investigadores (SNI II)

Programa Universitario de Estudios del Desarrollo (PUED)
Universidad Nacional Autónoma de México (UNAM)

Antigua Unidad de Posgrado (costado sur de la Torre II de Humanidades), planta baja.
Campus Central, Ciudad Universitaria, Ciudad de México, México.

Tel. (+52) 55 5623 0222, Ext. 82613 y 82616

Tel. (+52) 55 5622 0889

Email: hecatalan@hotmail.com, chuffman@unam.mx



*¡Bienvenidos
estudiantes!*

